



**BÁO CÁO ĐỒ ÁN CUỐI KỲ  
MÔN MÁY HỌC – CS114.Q21.KHTN**

**DỰ ĐOÁN TỶ LỆ KHÁCH HÀNG  
PHÒNG GYM NGỪNG SỬ DỤNG DỊCH VỤ**

**Giảng viên hướng dẫn:** Võ Nguyễn Lê Duy

**Nhóm sinh viên thực hiện:** Nhóm 5

Lê Thiên Quân – 24520027

Hà Bùi Trọng Nghĩa – 24520020

**TP. Hồ Chí Minh, tháng 5 năm 2026**

## CONTENTS

|             |                                                         |   |                   |                                                        |   |
|-------------|---------------------------------------------------------|---|-------------------|--------------------------------------------------------|---|
| <b>I</b>    | <b>Introduction</b>                                     | 2 | <b>IX</b>         | <b>Explainability and Business Interpretation</b>      | 7 |
| I-A         | Customer Churn và tác động kinh doanh                   | 2 | IX-A              | SHAP Global Importance . . . . .                       | 7 |
| I-B         | Gym Industry Context . . . . .                          | 2 | IX-B              | SHAP Summary Plot . . . . .                            | 7 |
| I-C         | Problem Statement . . . . .                             | 2 | IX-C              | Business Interpretation và Retention Mapping . . . . . | 8 |
| I-D         | Objectives . . . . .                                    | 2 | IX-D              | Customer Risk Personas . . . . .                       | 8 |
| I-E         | Contributions . . . . .                                 | 2 | <b>X</b>          | <b>Deployment System</b>                               | 8 |
| <b>II</b>   | <b>Related Work</b>                                     | 2 | X-A               | System Architecture . . . . .                          | 8 |
| II-A        | Customer Churn Prediction . . . . .                     | 2 | X-B               | Web Application Features . . . . .                     | 8 |
| II-B        | Machine Learning Methods for Churn Prediction . . . . . | 2 | X-C               | UI Design . . . . .                                    | 8 |
| II-C        | Explainable AI in Churn Prediction . . . . .            | 2 | X-D               | Deployment Workflow . . . . .                          | 9 |
| <b>III</b>  | <b>Dataset and Problem Definition</b>                   | 2 | X-E               | Source Code Repository . . . . .                       | 9 |
| III-A       | Dataset Overview . . . . .                              | 2 | <b>XI</b>         | <b>Conclusion and Future Work</b>                      | 9 |
| III-B       | Feature Description . . . . .                           | 3 | XI-A              | Conclusion . . . . .                                   | 9 |
| III-C       | Problem Definition . . . . .                            | 3 | XI-B              | Limitations . . . . .                                  | 9 |
| III-D       | Business Assumptions . . . . .                          | 3 | XI-C              | Future Work . . . . .                                  | 9 |
| <b>IV</b>   | <b>Exploratory Data Analysis</b>                        | 3 | <b>XII</b>        | <b>Task Distribution</b>                               | 9 |
| IV-A        | Data Quality . . . . .                                  | 3 | <b>References</b> |                                                        | 9 |
| IV-B        | Target Distribution . . . . .                           | 3 |                   |                                                        |   |
| IV-C        | Feature Distributions . . . . .                         | 3 |                   |                                                        |   |
| IV-D        | Correlation and Association Analysis . . . . .          | 3 |                   |                                                        |   |
| IV-E        | Statistical Hypothesis Testing . . . . .                | 4 |                   |                                                        |   |
| IV-F        | Key Insights . . . . .                                  | 4 |                   |                                                        |   |
| <b>V</b>    | <b>Methodology</b>                                      | 4 |                   |                                                        |   |
| V-A         | Workflow Pipeline . . . . .                             | 4 |                   |                                                        |   |
| V-B         | Train-Test Split . . . . .                              | 5 |                   |                                                        |   |
| V-C         | Evaluation Metrics . . . . .                            | 5 |                   |                                                        |   |
| V-D         | Baseline Models . . . . .                               | 5 |                   |                                                        |   |
| <b>VI</b>   | <b>Feature Engineering</b>                              | 5 |                   |                                                        |   |
| VI-A        | Design Philosophy . . . . .                             | 5 |                   |                                                        |   |
| VI-B        | Group A: Engagement Features . . . . .                  | 5 |                   |                                                        |   |
| VI-C        | Group B: Contract / Renewal Risk Features . . . . .     | 5 |                   |                                                        |   |
| VI-D        | Group C: Loyalty Features . . . . .                     | 5 |                   |                                                        |   |
| VI-E        | Group D: Interaction Features . . . . .                 | 5 |                   |                                                        |   |
| VI-F        | Group E: Convenience and Social Features . . . . .      | 5 |                   |                                                        |   |
| VI-G        | Group F: Log-Transformed Features . . . . .             | 5 |                   |                                                        |   |
| <b>VII</b>  | <b>Imbalance Handling</b>                               | 6 |                   |                                                        |   |
| VII-A       | Strategies Evaluated . . . . .                          | 6 |                   |                                                        |   |
| VII-B       | Results and Key Finding . . . . .                       | 6 |                   |                                                        |   |
| <b>VIII</b> | <b>Experimental Results</b>                             | 6 |                   |                                                        |   |
| VIII-A      | Baseline Results . . . . .                              | 6 |                   |                                                        |   |
| VIII-B      | Feature Engineering Impact . . . . .                    | 6 |                   |                                                        |   |
| VIII-C      | Cross-Validation Results . . . . .                      | 7 |                   |                                                        |   |
| VIII-D      | Discussion . . . . .                                    | 7 |                   |                                                        |   |

**Abstract**—Dự đoán churn khách hàng là một bài toán quan trọng trong ngành dịch vụ thể dục theo mô hình thuê bao, nơi việc giữ chân khách hàng có chi phí thấp hơn đáng kể so với thu hút khách hàng mới. Nghiên cứu này đề xuất một pipeline machine learning để dự đoán churn của khách hàng phòng gym trên bộ dữ liệu công khai gồm 4.000 mẫu và 13 đặc trưng. Phương pháp kết hợp exploratory data analysis (EDA), kiểm định thông kê, feature engineering dựa trên hành vi và explainable AI thông qua SHAP nhằm tạo ra các dự đoán vừa chính xác vừa có khả năng diễn giải. Hơn 30 đặc trưng mới được xây dựng từ các nhóm hành vi như mức độ tương tác, độ trung thành và rủi ro gia hạn hợp đồng. CatBoost đạt kết quả tốt nhất với ROC-AUC 0,9897 và F1-score 0,9294 sau feature engineering. Phân tích SHAP cho thấy `frequency_drop`, `engagement_score` và `loyalty_score` là các yếu tố ảnh hưởng lớn nhất đến churn. Hệ thống cuối cùng được triển khai thành ứng dụng web FastAPI hỗ trợ dự đoán và giải thích kết quả theo thời gian thực.

**Index Terms**—dự đoán churn, machine learning, feature engineering, SHAP, CatBoost, ngành fitness, explainable AI, giữ chân khách hàng

## I. INTRODUCTION

### A. Customer Churn và tác động kinh doanh

Customer churn - hiện tượng khách hàng ngừng sử dụng dịch vụ - là một thách thức lớn trong các mô hình kinh doanh thuê bao. Churn làm giảm doanh thu định kỳ và ảnh hưởng trực tiếp đến khả năng duy trì tăng trưởng của doanh nghiệp. Vì chi phí giữ chân khách hàng hiện có thường thấp hơn so với thu hút khách hàng mới, việc phát hiện sớm các khách hàng có nguy cơ rời bỏ trở thành bài toán có giá trị thực tiễn và kinh doanh cao.

### B. Gym Industry Context

Ngành thể dục thể thao là một môi trường churn phức tạp do hành vi tập luyện thường không ổn định và phụ thuộc nhiều vào động lực cá nhân. Hội viên phòng gym thường có xu hướng giảm mức độ tham gia sau giai đoạn đăng ký ban đầu, đặc biệt ở các hợp đồng ngắn hạn. Các yếu tố như tần suất tham dự thấp, hợp đồng sắp hết hạn, thiếu tương tác xã hội và vị trí không thuận tiện đều có thể làm tăng nguy cơ churn. Vì vậy, dự đoán churn đóng vai trò quan trọng trong việc hỗ trợ các chiến lược giữ chân khách hàng và tối ưu hoạt động kinh doanh của phòng gym.

### C. Problem Statement

Nghiên cứu này giải quyết bài toán: *Dựa trên các đặc trưng có thể quan sát được — nhân khẩu học, thông số hợp đồng và chỉ số hành vi — dự đoán liệu một khách hàng phòng gym có rời bỏ trong kỳ hợp đồng tiếp theo hay không*. Bài toán được định nghĩa là phân loại nhị phân có giám sát, trong đó lớp dương (Churn = 1) biểu thị các khách hàng ngừng gia hạn hội viên. Toàn bộ đặc trưng đều có thể quan sát được trước thời điểm dự đoán, đảm bảo hệ thống có thể triển khai trong môi trường thực tế mà không phát sinh rò rỉ dữ liệu.

### D. Objectives

Nghiên cứu hướng đến bốn mục tiêu chính: (i) xây dựng và đánh giá các mô hình machine learning cho bài toán dự đoán churn; (ii) thiết kế feature engineering dựa trên hành vi nhằm

khai thác các tín hiệu churn tiềm ẩn; (iii) tăng khả năng giải thích mô hình thông qua SHAP; và (iv) triển khai hệ thống thành ứng dụng web hỗ trợ dự đoán và giải thích churn theo thời gian thực.

## E. Contributions

Nghiên cứu đóng góp bốn điểm chính:

**C1 – Behavior-Driven Feature Engineering.** Xây dựng hơn 30 đặc trưng mới dựa trên các nhóm hành vi như engagement, loyalty và contract renewal risk, giúp cải thiện đáng kể hiệu suất mô hình.

**C2 – Explainable AI via SHAP.** Áp dụng SHAP để phân tích mức độ ảnh hưởng của từng đặc trưng ở cả mức toàn cục và từng khách hàng cụ thể.

**C3 – Retention Recommendation System.** Kết hợp kết quả SHAP với các chiến lược giữ chân như tái tương tác, ưu đãi gia hạn và khuyến khích tham gia lớp nhóm.

**C4 – Production-Style Deployment.** Triển khai hệ thống dưới dạng ứng dụng web FastAPI hỗ trợ dự đoán đơn lẻ, xử lý hàng loạt và giải thích mô hình.

## II. RELATED WORK

### A. Customer Churn Prediction

Dự đoán churn đã được nghiên cứu rộng rãi trong nhiều lĩnh vực như viễn thông, ngân hàng và thương mại điện tử. Các nghiên cứu này cho thấy dữ liệu hành vi khách hàng đóng vai trò quan trọng trong việc phát hiện sớm nguy cơ rời bỏ. Tuy nhiên, lĩnh vực phòng gym và thể dục thể thao vẫn còn ít nghiên cứu chuyên sâu, đặc biệt đối với các phương pháp dự đoán churn dựa trên machine learning.

### B. Machine Learning Methods for Churn Prediction

Các mô hình như Logistic Regression, Random Forest, XGBoost, LightGBM và CatBoost thường được sử dụng trong các bài toán churn prediction trên dữ liệu dạng bảng. Trong đó, các mô hình ensemble dựa trên cây quyết định thường đạt hiệu suất cao nhờ khả năng xử lý mối quan hệ phi tuyến và tương tác giữa các đặc trưng.

### C. Explainable AI in Churn Prediction

Bên cạnh hiệu suất dự đoán, khả năng giải thích mô hình cũng ngày càng được quan tâm. SHAP là một phương pháp phổ biến giúp xác định mức độ ảnh hưởng của từng đặc trưng đến kết quả dự đoán, từ đó hỗ trợ doanh nghiệp hiểu rõ nguyên nhân churn và xây dựng các chiến lược giữ chân khách hàng hiệu quả hơn.

## III. DATASET AND PROBLEM DEFINITION

### A. Dataset Overview

Bộ dữ liệu *Gym Customers Features and Churn*<sup>1</sup> bao gồm **4.000 bản ghi khách hàng** và **14 cột** (13 đặc trưng + 1 nhãn mục tiêu nhị phân). Bộ dữ liệu không có giá trị bị thiếu và không có hàng trùng lặp, xác nhận điều kiện thu thập sạch sẽ. Tỷ lệ churn tổng thể xấp xỉ **26,5%**, tạo thành mức mất cân bằng lớp nhẹ đến trung bình (tỷ lệ  $\approx 2,77 : 1$ ).

<sup>1</sup><https://www.kaggle.com/datasets/adrianvinueza/gym-customers-features-and-churn/data>




Figure 1. Phân phối lớp mục tiêu. Churn = 1 chiếm khoảng 26,5% tổng số mẫu trong bộ dữ liệu.

## B. Feature Description

Bảng I tóm tắt 13 đặc trưng đầu vào theo từng nhóm loại. Đặc trưng nhị phân được mã hóa 0/1; đặc trưng rời rạc nhận các giá trị nguyên nhỏ; đặc trưng liên tục trải dài trên các phạm vi số rộng hơn.

Table I  
MÔ TẢ ĐẶC TRƯNG BỘ DỮ LIỆU

| Đặc trưng       | Kiểu     | Ý nghĩa nghiệp vụ                    |
|-----------------|----------|--------------------------------------|
| gender          | Nhị phân | Giới tính khách hàng                 |
| Near_Location   | Nhị phân | Sống gần phòng gym (1 = có)          |
| Partner         | Nhị phân | Khách hàng thuộc công ty đối tác     |
| Promo_friends   | Nhị phân | Tham gia qua bạn bè giới thiệu       |
| Phone           | Nhị phân | Để lại số điện thoại                 |
| Group_visits    | Nhị phân | Tham gia lớp tập nhóm                |
| Contract_period | Rời rạc  | Thời hạn hợp đồng (tháng)            |
| Month_to_end    | Rời rạc  | Số tháng đến khi hết hạn             |
| Age             | Liên tục | Tuổi khách hàng (năm)                |
| Avg_add_charges | Liên tục | Chi tiêu dịch vụ phụ trung bình      |
| Lifetime        | Liên tục | Thâm niên hội viên (tháng)           |
| Avg_freq_total  | Liên tục | Tần suất tập trung bình toàn lịch sử |
| Avg_freq_curr   | Liên tục | Tần suất tập tháng hiện tại          |

## C. Problem Definition

Bài toán được định nghĩa là phân loại nhị phân:

$$\hat{y} = f(\mathbf{x}) \in \{0, 1\}, \quad y = 1 \Rightarrow \text{Churn}, \quad y = 0 \Rightarrow \text{Giữ lại}.$$

Toàn bộ đặc trưng đều có thể quan sát được trước thời điểm dự đoán, đảm bảo không có rò rỉ nhãn mục tiêu (target leakage). Việc đánh giá ưu tiên Recall và F1-score cho lớp dương, cho thấy việc nếu bỏ sót một khách hàng churn thực sự (false negative) gây hậu quả nghiêm trọng hơn so với một cảnh báo sai (false positive).

## D. Business Assumptions

Hai giả định hành vi định hướng thiết kế đặc trưng: (A1) Sự giảm tần suất tham gia buổi tập so với mức cơ sở lịch sử của khách hàng báo hiệu sự mất gắn kết và nguy cơ churn gia tăng; (A2) Sự tiếp cận ngưỡng hết hạn hợp đồng, đặc biệt khi kết hợp với mức độ tham dự thấp là dấu hiệu dự báo mạnh cho việc không gia hạn. Cả hai giả định đều được xác nhận bằng kiểm định thống kê trong Mục IV.

## IV. EXPLORATORY DATA ANALYSIS

### A. Data Quality

Kiểm tra toàn diện bộ dữ liệu xác nhận **không có giá trị bị thiếu** và **không có hàng trùng lặp**. Tất cả đặc trưng đều ở dạng số (nhị phân, rời rạc hoặc liên tục), không cần mã hóa phân loại.

### B. Target Distribution

Như minh họa trong Hình 1, 73,5% khách hàng được giữ lại (Churn = 0) trong khi 26,5% rời bỏ (Churn = 1). Mức mất cân bằng vừa phải này không ngăn các mô hình máy học tiêu chuẩn học được ranh giới quyết định hữu ích, nhưng nó tạo động lực cho việc đánh giá định hướng Recall.

### C. Feature Distributions

Đặc trưng Lifetime theo phân phối lệch phải với phần lớn khách hàng tập trung trong khoảng 0–6 tháng, cho thấy nguy cơ churn cao ở giai đoạn đầu. Đặc trưng Avg\_class\_frequency\_current\_month thể hiện mô hình phân phối hai đỉnh - một cụm lớn gần 0–1 buổi/tuần (mức độ tương tác thấp) và một cụm phụ khoảng 3–4 buổi/tuần — trong đó các khách hàng churn tập trung áp đảo ở cụm mức độ tương tác thấp.




Figure 2. Phân phối đặc trưng Lifetime (histogram + boxplot). Phân phối lệch phải, phần lớn hội viên có thâm niên dưới 6 tháng.

### D. Correlation and Association Analysis

Do tập dữ liệu bao gồm cả biến liên tục, biến nhị phân và biến phân loại/thứ bậc, nghiên cứu sử dụng nhiều phép đo khác nhau để đánh giá mối liên hệ với biến mục tiêu Churn. Cụ thể, tương quan Pearson và Spearman được áp dụng cho nhóm đặc trưng số, trong khi kiểm định Chi-square được sử dụng cho các biến phân loại và nhị phân.

Hình 3 và Hình 4 trình bày ma trận tương quan Pearson và Spearman cho các đặc trưng số. Kết quả cho thấy các biến liên quan đến mức độ gắn bó và hoạt động của khách hàng như Lifetime, Avg\_class\_frequency\_current\_month và Month\_to\_end\_contract có liên hệ đáng kể với khả năng churn. Spearman cho kết quả tương đối nhất quán với Pearson, đồng thời phù hợp hơn với các dữ liệu có phân phối lệch hoặc quan hệ không hoàn toàn tuyến tính.

Đối với các biến phân loại và nhị phân, kết quả kiểm định Chi-square cho thấy các đặc trưng như Contract\_period, Group\_visits, Partner và Near\_Location đều có liên hệ thống kê đáng kể với Churn. Điều này cho thấy yếu tố về hợp đồng, mức độ tham gia theo nhóm và sự thuận tiện về vị trí đều ảnh hưởng đến khả năng rời bỏ của khách hàng.

Cuối cùng, Hình 5 tổng hợp mức độ liên hệ giữa các đặc trưng và biến mục tiêu Churn. Các kết quả này được sử dụng làm cơ sở cho bước feature engineering ở các giai đoạn sau, đặc biệt đối với các nhóm đặc trưng liên quan đến *engagement*, *loyalty* và *contract renewal risk*. Cần lưu ý rằng các phân tích này chỉ phản ánh mối liên hệ thống kê, không khẳng định quan hệ nhân quả.




Figure 3. Ma trận tương quan Pearson cho nhóm đặc trưng số.




Figure 4. Ma trận tương quan Spearman cho nhóm đặc trưng số.




Figure 5. Mức độ liên hệ giữa các đặc trưng và biến mục tiêu Churn.

### E. Statistical Hypothesis Testing

Để xác nhận các giả định hành vi (A1) và (A2), chúng tôi áp dụng ba kiểm định bổ trợ nhau:

**Kiểm định Mann-Whitney U** (phi tham số) cho các đặc trưng liên tục. Kết quả xác nhận rằng Avg\_class\_frequency\_current\_month ( $p \ll 0,001$ ), Lifetime ( $p \ll 0,001$ ) và Month\_to\_end\_contract ( $p \ll 0,001$ ) khác biệt có ý nghĩa thống kê giữa nhóm churn và nhóm giữ lại.

**Kiểm định Chi-square** cho các đặc trưng nhị phân. Contract\_period, Group\_visits, Partner và Promo\_friends đều cho thấy mối liên hệ thống kê có ý nghĩa với churn ( $\chi^2, p < 0,001$ ), trong khi gender không cho thấy mối liên hệ đáng kể ( $p = 0,48$ ), xác nhận đây là đặc trưng không có giá trị dự đoán.

**Hệ số Cohen's d** (kích thước hiệu ứng). Đặc trưng Avg\_class\_frequency\_current\_month đạt kích thước hiệu ứng lớn nhất ( $d \approx 1,4$ , hiệu ứng lớn), tiếp theo là Lifetime ( $d \approx 1,1$ ) và Month\_to\_end\_contract ( $d \approx 0,9$ ). Các kích thước hiệu ứng lớn này cung cấp cơ sở thực nghiệm mạnh mẽ để tập trung chiến lược trích xuất đặc trưng vào việc sụt giảm tần suất tham dự và khoảng cách thời gian đến ngày hết hạn hợp đồng.

### F. Key Insights

**Mức độ tương tác (Engagement):** Khách hàng có Avg\_freq\_curr < 1 buổi/tuần cho thấy tỷ lệ churn vượt quá 60%, so với dưới 10% đối với những người tập ≥ 3 buổi/tuần. Tần suất tham dự là tín hiệu churn quan sát được mạnh nhất.

**Sự trung thành (Loyalty):** Hội viên có Lifetime ≤ 1 tháng có tỷ lệ churn > 55%. Sau 6 tháng, nguy cơ churn giảm xuống dưới 15%, minh họa tầm quan trọng thiết yếu của cửa sổ hội viên đầu tiên.

**Rủi ro hợp đồng (Contract Risk):** Month\_to\_end\_contract = 0 có tương quan với tỷ lệ churn > 80%. Khách hàng có hợp đồng theo tháng (Contract\_period = 1) rời bỏ với tỷ lệ gấp khoảng 3 lần so với những người có hợp đồng 12 tháng.

## V. METHODOLOGY

### A. Workflow Pipeline

Pipeline từ đầu đến cuối tuân theo cấu trúc tuần tự nghiêm ngặt được thiết kế để ngăn rò rỉ dữ liệu ở mọi giai đoạn:

- 1) **Dữ liệu thô** → EDA và kiểm định thống kê
- 2) **Train/Test Split** (trước mọi biến đổi)
- 3) **Feature Engineering** (fit ngưỡng chỉ trên tập train)
- 4) **Tiền xử lý** (StandardScaler cho mô hình tuyến tính)
- 5) **Huấn luyện mô hình** (baseline + thí nghiệm FE)
- 6) **Xử lý mất cân bằng** (lấy mẫu chỉ trên tập train)
- 7) **SHAP Explainability** (trên tập test giữ lại)
- 8) **Triển khai** (FastAPI + hệ thống khuyến nghị giữ chân)

### B. Train-Test Split

Tất cả các thí nghiệm sử dụng phân chia stratified 80/20 với `random_state = 42`. Phân tầng bảo toàn tỷ lệ churn  $\approx 26,5\%$  ở cả hai phân vùng. Tập train: 3.200 mẫu; tập test: 800 mẫu. Tất cả các ngưỡng feature engineering và tham số tiền xử lý đều được fit độc quyền trên tập train và áp dụng giống nhau cho tập test.

### C. Evaluation Metrics

Dựa trên mức mất cân bằng lớp vừa phải và sự bất đối xứng chi phí nghiệp vụ, chúng tôi báo cáo năm chỉ số: **Accuracy** (độ chính xác tổng thể), **Precision** (tỷ lệ dự đoán churn đúng), **Recall** (tỷ lệ phát hiện đúng khách hàng churn thực sự), **F1-score** (trung bình điều hòa của Precision và Recall), và **ROC-AUC** (chất lượng xếp hạng trên tất cả các ngưỡng). **PR-AUC** cũng được báo cáo trong các thí nghiệm xử lý mất cân bằng vì độ nhạy cao hơn với hiệu ứng mất cân bằng lớp. Recall và F1 được coi là chỉ số nghiệp vụ chính vì bỏ sót một khách hàng churn (false negative) gây tổn thất lớn hơn về mặt vận hành so với cảnh báo sai (false positive).

### D. Baseline Models

Mười một bộ phân loại baseline được đánh giá: Logistic Regression,  $k$ -Nearest Neighbors, Decision Tree, Random Forest, Extra Trees, Gradient Boosting, AdaBoost, SVM (nhân RBF), XGBoost, LightGBM và CatBoost. Tất cả các mô hình sử dụng siêu tham số mặc định hoặc được tinh chỉnh nhẹ để thiết lập so sánh ban đầu công bằng. Các mô hình tuyến tính (LR, SVM) sử dụng StandardScaler; các mô hình dựa trên cây sử dụng đầu vào số thô.

## VI. FEATURE ENGINEERING

### A. Design Philosophy

Các đặc trưng gốc chủ yếu phản ánh thuộc tính khách hàng ở trạng thái tĩnh. Mục tiêu của feature engineering là xây dựng các tín hiệu hành vi có khả năng phản ánh trực tiếp nguy cơ churn được phát hiện trong giai đoạn EDA. Các đặc trưng mới được nhóm theo các khái niệm nghiệp vụ như mức độ tương tác, mức độ trung thành và rủi ro gia hạn hợp đồng.

### B. Group A: Engagement Features

Nhóm đặc trưng này đo lường mức độ tham gia hiện tại của khách hàng. `frequency_drop` biểu diễn mức suy giảm tần suất tập luyện so với mức trung bình lịch sử, trong khi `frequency_ratio_current_total` chuẩn hóa hoạt động hiện tại theo hành vi trước đó của từng khách hàng. `engagement_score` kết hợp tham

niên và tần suất tập hiện tại nhằm phản ánh cường độ gắn bó tổng thể. Ngoài ra, `low_current_activity` và `high_current_activity` được sử dụng để đánh dấu các nhóm khách hàng có mức tham gia cực thấp hoặc cực cao.

### C. Group B: Contract / Renewal Risk Features

Nhóm đặc trưng này tập trung vào rủi ro gia hạn hợp đồng. `contract_remaining_ratio` đo tỷ lệ thời gian hợp đồng còn lại, trong khi `is_contract_ending` xác định các khách hàng sắp hết hạn hợp đồng. `renewal_pressure_score` kết hợp rủi ro hết hạn với hợp đồng ngắn hạn nhằm xác định các trường hợp có nguy cơ churn cao nhất.

### D. Group C: Loyalty Features

Các đặc trưng loyalty phản ánh mức độ cam kết dài hạn của khách hàng. `loyalty_score` kết hợp thời gian tham gia và độ dài hợp đồng để đo mức độ trung thành tích lũy. Bên cạnh đó, `is_new_customer` và `is_loyal_customer` được sử dụng để phân biệt khách hàng mới và khách hàng gắn bó lâu dài.

### E. Group D: Interaction Features

Các đặc trưng tương tác được xây dựng nhằm mô hình hóa các hiệu ứng phi tuyến giữa nhiều yếu tố rủi ro. Ví dụ, `new_low_activity` xác định các khách hàng mới nhưng đã có mức độ tham gia thấp, trong khi `ending_low_activity` kết hợp giữa hợp đồng sắp hết hạn và tần suất tập thấp. Ngoài ra, các đặc trưng như `no_group_low_activity`, `far_low_activity` và `short_contract_low_activity` giúp phát hiện các trường hợp rủi ro kết hợp liên quan đến yếu tố xã hội, vị trí và cấu trúc hợp đồng.

### F. Group E: Convenience and Social Features

Nhóm đặc trưng này phản ánh mức độ thuận tiện và hòa nhập xã hội của khách hàng. `convenience_score` tổng hợp các tín hiệu như vị trí gần phòng gym, tham gia qua giới thiệu hoặc cung cấp thông tin liên hệ. `social_commitment_score` đánh giá mức độ gắn kết xã hội thông qua tham gia lớp nhóm, mạng lưới giới thiệu và quan hệ đối tác.

### G. Group F: Log-Transformed Features

Các phép biến đổi logarithm được áp dụng cho các đặc trưng có phân phối lệch như `Lifetime`, `Avg_additional_charges` và các biến tần suất nhằm giảm ảnh hưởng của outlier và ổn định phương sai. Sau quá trình feature engineering, không gian đặc trưng được mở rộng từ **13 đặc trưng gốc** lên **46 đặc trưng**, bổ sung thêm 33 đặc trưng được kỹ thuật hóa.






Figure 6. Top 15 đặc trưng được kỹ thuật hóa theo tương quan tuyệt đối với Churn. Các đặc trưng liên quan đến engagement, loyalty và contract risk cho thấy tín hiệu dự đoán mạnh nhất.

## VII. IMBALANCE HANDLING

### A. Strategies Evaluated

Bốn chiến lược oversampling và một phương pháp cân bằng trọng số lớp được kiểm tra trên bộ dữ liệu đã được feature engineering: (i) Random Oversampler, (ii) SMOTE [8], (iii) Borderline-SMOTE [9], (iv) ADASYN [10], và (v) cân bằng trọng số lớp (class-weight balancing). Việc oversampling được áp dụng nghiêm ngặt bên trong pipeline của `imbalanced-learn` để đảm bảo tập test không bao giờ bị lấy mẫu lại.

### B. Results and Key Finding

Bảng II so sánh kết quả tốt nhất từ mỗi chiến lược. Cần lưu ý rằng bảng báo cáo mô hình tốt nhất của từng chiến lược, do đó mô hình tối ưu có thể khác nhau giữa các phương pháp. Phát hiện quan trọng là mức mất cân bằng của bộ dữ liệu không đủ nghiêm trọng để oversampling hay cân bằng trọng số lớp cải thiện đáng kể hiệu suất. Kết quả oversampling tốt nhất (RandomOverSampler + XGBoost) đạt Recall cao hơn nhẹ (0,9245), nhưng ROC-AUC chỉ dao động quanh mức 0,986 – 0,988. Điều này cho thấy tỷ lệ churn  $\approx 26,5\%$  đại diện cho mức mất cân bằng nhẹ, đủ để các mô hình boosting mạnh hoạt động hiệu quả mà không cần xử lý mất cân bằng quá phức tạp.

Table II  
KẾT QUẢ TỐT NHẤT KHI XỬ LÝ MẤT CÂN BẰNG DỮ LIỆU

| Chiến lược        | Mô hình     | Recall | F1     | AUC    | PR     |
|-------------------|-------------|--------|--------|--------|--------|
| Không xử lý       | Rnd. Forest | 0,9104 | 0,9324 | 0,9885 | 0,9764 |
| Class Weight      | Rnd. Forest | 0,9057 | 0,9320 | 0,9885 | 0,9755 |
| RandomOverSampler | XGBoost     | 0,9245 | 0,9267 | 0,9856 | 0,9719 |
| SMOTE             | XGBoost     | 0,9151 | 0,9173 | 0,9868 | 0,9732 |
| B-SMOTE           | XGBoost     | 0,9198 | 0,9198 | 0,9876 | 0,9738 |
| ADASYN            | XGBoost     | 0,9198 | 0,9198 | 0,9862 | 0,9713 |

## VIII. EXPERIMENTAL RESULTS

### A. Baseline Results

Bảng III báo cáo kết quả của 11 mô hình baseline trên đặc trưng thô (tập test). CatBoost đạt ROC-AUC cao nhất là 0,9826, tiếp theo là XGBoost (0,9800) và LightGBM (0,9775). Logistic Regression cung cấp baseline tuyến tính mạnh (ROC-AUC = 0,9774) nhờ các đặc trưng thô có thể phân tách tốt. Decision

Tree bị overfit rõ ràng (accuracy = 0,9050 nhưng ROC-AUC = 0,8720), xác nhận sự cần thiết của các phương pháp ensemble.

Table III  
HIỆU SUẤT MÔ HÌNH BASELINE (ĐẶC TRƯNG THÔ, TẬP TEST)

| Mô hình         | Acc.   | F1     | AUC           | Prec.  |
|-----------------|--------|--------|---------------|--------|
| CatBoost        | 0,9475 | 0,8990 | <b>0,9826</b> | 0,9167 |
| XGBoost         | 0,9450 | 0,8947 | 0,9800        | 0,9078 |
| LightGBM        | 0,9425 | 0,8883 | 0,9775        | 0,9150 |
| Log. Regression | 0,9250 | 0,8544 | 0,9774        | 0,8800 |
| Grad. Boosting  | 0,9437 | 0,8905 | 0,9774        | 0,9196 |
| SVM (RBF)       | 0,9350 | 0,8732 | 0,9704        | 0,9040 |
| Random Forest   | 0,9250 | 0,8537 | 0,9684        | 0,8838 |
| AdaBoost        | 0,9163 | 0,8378 | 0,9653        | 0,8607 |
| Extra Trees     | 0,9137 | 0,8305 | 0,9579        | 0,8667 |
| KNN             | 0,8900 | 0,7864 | 0,9199        | 0,8100 |
| Decision Tree   | 0,9050 | 0,8173 | 0,8720        | 0,8333 |




Figure 7. So sánh đường cong ROC của các mô hình baseline chính. CatBoost chiếm ưu thế trên toàn bộ phạm vi ngưỡng.

### B. Feature Engineering Impact

Bảng IV báo cáo mức cải thiện hiệu suất nhờ feature engineering cho bốn mô hình mạnh nhất. CatBoost được hưởng lợi nhiều nhất, với ROC-AUC cải thiện từ 0,9826 lên **0,9897** ( $\Delta = +0,0071$ ) và F1 từ 0,8990 lên **0,9294** ( $\Delta = +0,0304$ ). Các mô hình boosting và Random Forest đều cải thiện đáng kể sau feature engineering, đặc biệt là CatBoost và LightGBM. Logistic Regression cũng cải thiện nhẹ, cho thấy các đặc trưng kỹ thuật hóa cung cấp thêm tín hiệu phân tách tuyến tính so với không gian đặc trưng gốc.

Table IV  
TÁC ĐỘNG FEATURE ENGINEERING LÊN ROC-AUC VÀ F1

| Mô hình         | ROC-AUC |               | F1     |               |
|-----------------|---------|---------------|--------|---------------|
|                 | Gốc     | FE            | Gốc    | FE            |
| CatBoost        | 0,9826  | <b>0,9897</b> | 0,8990 | <b>0,9294</b> |
| XGBoost         | 0,9800  | 0,9885        | 0,8947 | 0,9165        |
| LightGBM        | 0,9782  | 0,9895        | 0,8873 | 0,9108        |
| Random Forest   | 0,9683  | 0,9884        | 0,8564 | 0,9372        |
| Grad. Boosting  | 0,9774  | 0,9884        | 0,8905 | 0,9249        |
| Log. Regression | 0,9774  | 0,9779        | 0,8544 | 0,8675        |




Figure 8. So sánh hiệu suất Gốc vs Feature Engineered trên các mô hình (ROC-AUC và F1). Mọi mô hình đều được cải thiện sau khi thêm đặc trưng kỹ thuật hóa.

### C. Cross-Validation Results

Để xác nhận rằng các cải thiện không phải do ngẫu nhiên từ tập test, kiểm định chéo phân tầng 5-fold được thực hiện trên mô hình CatBoost trước và sau feature engineering. Bảng V trình bày giá trị trung bình và độ lệch chuẩn của ROC-AUC. CatBoost đạt ROC-AUC trung bình là  $0,9900 \pm 0,0033$ , thể hiện tính ổn định tổng quát hóa mạnh. Độ lệch chuẩn thấp xác nhận rằng lợi ích của feature engineering là nhất quán và không phụ thuộc vào từng fold cụ thể.

Table V  
KẾT QUẢ CROSS-VALIDATION 5-FOLD(CATBOOST)

| Thiết lập          | Mean AUC      | Std AUC | Mean F1       |
|--------------------|---------------|---------|---------------|
| Original           | 0,9858        | 0,0045  | 0,9008        |
| Feature Engineered | <b>0,9900</b> | 0,0033  | <b>0,9161</b> |

### D. Discussion

**Lý do boosting vượt trội.** Các cây gradient boosting (CatBoost, XGBoost, LightGBM) xuất sắc vì churn được thúc đẩy bởi các tương tác phức tạp, phi tuyến giữa các đặc trưng - ví dụ: sự kết hợp giữa hợp đồng ngắn, tần suất tham dự thấp và bất tiện địa lý không được nắm bắt bởi các mô hình tuyến tính hoặc cây đơn lẻ. Boosting mô hình hóa rõ ràng các hiệu ứng tương tác bậc cao này thông qua hiệu chỉnh phần dư tuần tự.

**Lý do feature engineering có hiệu quả.** Các đặc trưng được kỹ thuật hóa (đặc biệt là `frequency_drop`, `engagement_score` và `loyalty_score`) nén các tín hiệu hành vi đa đặc trưng thành các biến dự đoán đơn lẻ, giảm không gian tìm kiếm mà bộ học phải điều hướng. Các đặc trưng tương tác (`ending_low_activity`, `new_low_activity`) trực tiếp mã hóa các giả thuyết rủi ro kết hợp.

**Lý do xử lý mất cân bằng không mang lại lợi ích đáng kể.** Ở tỷ lệ churn  $\approx 26,5\%$ , ranh giới quyết định đã được hỗ trợ đầy đủ bởi lớp thiểu số. Oversampling thêm nhiều tổng hợp trong một vùng đã được bao phủ, trong khi tái trọng số lặp nội tại của boosting đã xử lý mất cân bằng nhẹ một cách hiệu quả.

## IX. EXPLAINABILITY AND BUSINESS INTERPRETATION

### A. SHAP Global Importance

Hình 9 trình bày top 20 đặc trưng được xếp hạng theo giá trị SHAP tuyệt đối trung bình, được tính trên tập test giữ lại bằng TreeExplainer của CatBoost. Bốn đặc trưng hàng đầu đều là các đặc trưng được kỹ thuật hóa: `frequency_drop`, `engagement_score`, `loyalty_score` và `contract_remaining_ratio`, chứng minh rằng quá trình tổng hợp hành vi bổ sung tín hiệu dự đoán vượt ngoài các đầu vào thô. Trong số các đặc trưng thô, `Lifetime`, `Avg_class_frequency_current_month` và `Month_to_end_contract` xếp hạng cao nhất.




Figure 9. Top 20 độ quan trọng đặc trưng SHAP toàn cục (mean |SHAP value| trên tập test). Các đặc trưng hành vi được kỹ thuật hóa chiếm ưu thế trong bảng xếp hạng.

### B. SHAP Summary Plot

Biểu đồ beeswarm tổng hợp (Hình 10) tiết lộ *hướng* tác động của từng đặc trưng: `frequency_drop`: giá trị cao (mức giảm tần suất lớn)  $\rightarrow$  SHAP dương  $\rightarrow$  *tăng xác suất churn*. `engagement_score`: giá trị cao (thâm niên dài, hoạt động nhiều)  $\rightarrow$  SHAP âm  $\rightarrow$  *giảm xác suất churn*. `contract_remaining_ratio`: giá trị thấp (hợp đồng gần hết hạn)  $\rightarrow$  SHAP dương  $\rightarrow$  nguy cơ churn tăng cao. Những diễn giải hướng tác động này khớp chính xác với các giả thuyết nghiệp vụ được đặt ra trong Mục IV, cung cấp bước kiểm tra tính nhất quán giữa phân tích thống kê và hành vi mô hình.





Figure 10. Biểu đồ beeswarm SHAP. Màu đỏ = giá trị đặc trưng cao, Màu xanh = giá trị thấp. SHAP dương = tăng xác suất churn. SHAP âm = giảm xác suất churn.

### C. Business Interpretation và Retention Mapping

Bảng VI ánh xạ các yếu tố tác động SHAP hàng đầu sang các hành động giữ chân cụ thể, tạo thành cơ sở của hệ thống khuyến nghị trong triển khai.

Table VI  
ÁNH XẠ TỪ DRIVER SHAP SANG HÀNH ĐỘNG GIỮ CHÂN

| Yếu tố churn          | Hành động giữ chân đề xuất                                                                |
|-----------------------|-------------------------------------------------------------------------------------------|
| frequency_drop cao    | Khởi động chiến dịch tái tương tác; gửi nhắc nhở lịch tập; ưu đãi buổi PT miễn phí        |
| engagement_score thấp | Hỗ trợ onboarding cho hội viên mới; check-in định kỳ xây dựng thói quen; mời lớp tập nhóm |
| loyalty_score thấp    | Giới thiệu chương trình khách hàng trung thành; ưu đãi gia hạn cam kết dài hạn            |
| Hợp đồng sắp hết hạn  | Tiếp cận gia hạn chủ động; chiết khấu gia hạn sớm trước 2-4 tuần                          |
| ending_low_activity   | Ưu tiên cao nhất: kết hợp PT + ưu đãi gia hạn + liên lạc trực tiếp                        |
| far_no_group          | Mời tham gia lớp nhóm theo khung giờ thuận tiện; quảng bá lớp học trực tuyến              |

### D. Customer Risk Personas

Dựa trên phân tích cụm SHAP, bốn rủi ro điển hình xuất hiện:

**P1 – Silent Drifter:** Hội viên lâu năm với tần suất tham dự giảm nhanh chóng. frequency\_drop cao, loyalty\_score vừa phải. Rủi ro: thói quen bị gián đoạn. Hành động: chiến dịch tái tương tác.

**P2 – Contract Cliffhanger:** Hợp đồng ngắn sắp hết hạn, tần suất tham dự vừa phải, không có mạng lưới giới thiệu.

is\_contract\_ending cao. Rủi ro: không gia hạn. Hành động: ưu đãi gia hạn.

**P3 – Early Dropout:** Hội viên mới ( $\leq 2$  tháng) với tần suất tham dự thấp ngay lập tức. new\_low\_activity cao. Rủi ro: thất bại trong onboarding. Hành động: tiếp cận cá nhân khẩn cấp.

**P4 – Isolated Member:** Địa điểm xa, không tham gia lớp nhóm, không có đồng hành. far\_no\_group cao. Rủi ro: cô lập xã hội. Hành động: tích hợp vào cộng đồng.

## X. DEPLOYMENT SYSTEM

### A. System Architecture

Hệ thống được triển khai bằng **FastAPI** kết hợp với mô hình CatBoost đã huấn luyện và module giải thích SHAP. Quy trình xử lý bao gồm: dữ liệu khách hàng đầu vào  $\rightarrow$  feature engineering  $\rightarrow$  dự đoán xác suất churn  $\rightarrow$  giải thích SHAP  $\rightarrow$  sinh khuyến nghị giữ chân. Toàn bộ pipeline được đóng gói để đảm bảo tính nhất quán giữa giai đoạn huấn luyện và triển khai.




Figure 11. Kiến trúc hệ thống triển khai. Dữ liệu đầu vào được xử lý qua feature engineering, mô hình CatBoost và module giải thích SHAP trước khi trả về kết quả dự đoán và khuyến nghị.

### B. Web Application Features

Ứng dụng web hỗ trợ ba chức năng chính:

**Dự đoán đơn lẻ:** Người dùng nhập thông tin khách hàng và hệ thống trả về xác suất churn, mức độ rủi ro và các nguyên nhân chính dẫn đến dự đoán.

**Dự đoán hàng loạt:** Người dùng có thể tải lên tệp CSV chứa nhiều khách hàng; hệ thống xử lý toàn bộ dữ liệu và xuất báo cáo kết quả.


**Giải thích mô hình:** Hệ thống hiển thị các đặc trưng ảnh hưởng mạnh nhất đến dự đoán churn thông qua SHAP, hỗ trợ việc phân tích và ra quyết định.

### C. UI Design

Giao diện ứng dụng được thiết kế theo phong cách *glass-morphism* với bố cục dashboard hiện đại và responsive. Các thành phần chính bao gồm thẻ hiển thị rủi ro, biểu đồ đóng góp đặc trưng và khu vực hiển thị khuyến nghị giữ chân khách hàng.

#### D. Deployment Workflow

Quy trình dự đoán của hệ thống được mô tả như sau:



Các artifact của mô hình và tham số feature engineering được lưu bằng `joblib` nhằm đảm bảo khả năng tái sử dụng và triển khai nhất quán trên hệ thống.

#### E. Source Code Repository

Mã nguồn của toàn bộ dự án, bao gồm notebooks, mô hình huấn luyện, ứng dụng FastAPI và slide trình bày được công khai tại:

<https://github.com/lethienquan28052006/CS114-Coursework>

### XI. CONCLUSION AND FUTURE WORK

#### A. Conclusion

Nghiên cứu đã xây dựng một hệ thống dự đoán churn cho khách hàng phòng gym dựa trên machine learning, feature engineering và SHAP. Các đặc trưng hành vi được kỹ thuật hóa giúp cải thiện đáng kể hiệu suất mô hình, trong đó CatBoost đạt kết quả tốt nhất với ROC-AUC 0,9897 và F1-score 0,9294.

Kết quả cho thấy các yếu tố liên quan đến mức độ tham gia, độ trung thành và rủi ro gia hạn hợp đồng là những tín hiệu dự đoán churn quan trọng nhất. Ngoài ra, hệ thống đã được triển khai thành ứng dụng web FastAPI hỗ trợ dự đoán và giải thích churn theo thời gian thực.

#### B. Limitations

Nghiên cứu vẫn còn một số hạn chế. Bộ dữ liệu có quy mô tương đối nhỏ và chưa phản ánh đầy đủ nhiều nhóm khách hàng khác nhau. Dữ liệu cũng không chứa chuỗi thời gian chi tiết nên chưa thể mô hình hóa đầy đủ sự thay đổi hành vi theo thời gian. Ngoài ra, các phân tích SHAP và tương quan chỉ phản ánh mối liên hệ thống kê, chưa đủ để kết luận quan hệ nhân quả.

#### C. Future Work

Trong tương lai, nghiên cứu có thể mở rộng theo hướng sử dụng các mô hình deep learning như LSTM hoặc Transformer trên dữ liệu chuỗi thời gian. Hệ thống cũng có thể được phát triển thành nền tảng dự đoán churn thời gian thực và tích hợp causal inference để đánh giá hiệu quả thực sự của các chiến lược giữ chân khách hàng.

### XII. TASK DISTRIBUTION

Nhóm thực hiện dự án gồm hai thành viên với phân công công việc như sau:

Table VII  
PHÂN CÔNG CÔNG VIỆC

| Thành viên         | Công việc phụ trách                                                                                           |
|--------------------|---------------------------------------------------------------------------------------------------------------|
| Lê Thiên Quân      | Tìm hiểu các mô hình machine learning, đánh giá kết quả mô hình, viết báo cáo, thuyết trình, triển khai demo. |
| Hà Bùi Trọng Nghĩa | Tìm hiểu và cài đặt các mô hình machine learning, thiết kế slide trình bày, triển khai demo.                  |

### REFERENCES

- [1] Y. Xie, X. Li, E. W. T. Ngai, and W. Ying, "Customer churn prediction using improved balanced random forests," *Expert Systems with Applications*, vol. 36, no. 3, pp. 5445–5449, 2009.
- [2] D. W. Hosmer, S. Lemeshow, and R. X. Sturdivant, *Applied Logistic Regression*, 3rd ed. Wiley, 2013.
- [3] L. Breiman, "Random forests," *Machine Learning*, vol. 45, no. 1, pp. 5–32, 2001.
- [4] T. Chen and C. Guestrin, "XGBoost: A scalable tree boosting system," in *Proc. 22nd ACM SIGKDD*, San Francisco, CA, 2016, pp. 785–794.
- [5] L. Prokhorenkova, G. Gusev, A. Veronika, A. V. Dorogush, and A. Gulin, "CatBoost: Unbiased boosting with categorical features," in *Proc. NeurIPS*, Montreal, QC, 2018, pp. 6638–6648.
- [6] S. M. Lundberg and S.-I. Lee, "A unified approach to interpreting model predictions," in *Proc. NeurIPS*, Long Beach, CA, 2017, pp. 4765–4774.
- [7] F. Devriendt, J. Berrevoets, and W. Verbeke, "Why you should stop predicting customer churn and start using uplift models," *Information Sciences*, vol. 548, pp. 497–515, 2021.
- [8] N. V. Chawla, K. W. Bowyer, L. O. Hall, and W. P. Kegelmeyer, "SMOTE: Synthetic minority over-sampling technique," *Journal of Artificial Intelligence Research*, vol. 16, pp. 321–357, 2002.
- [9] H. Han, W.-Y. Wang, and B.-H. Mao, "Borderline-SMOTE: A new over-sampling method in imbalanced data sets learning," in *Proc. ICIC*, Hefei, China, 2005, pp. 878–887.
- [10] H. He, Y. Bai, E. A. Garcia, and S. Li, "ADASYN: Adaptive synthetic sampling approach for imbalanced learning," in *Proc. IEEE IJCNN*, Hong Kong, 2008, pp. 1322–1328.